Fatores Socioeconômicos, Escolares e o Desempenho em Matemática no ENEM: Uma Análise Empírica e Preditiva no Distrito Federal (2021–2023)

Ana Caroline Freitas Brito (242001526), Ana Sarah Nagata (242023176), Kamily Silva Andrade Crispim (242009945)

Departamento de Ciência da Computação (CIC) – Universidade de Brasília (UnB)
Brasília – DF – Brasil

Resumo

O Exame Nacional do Ensino Médio (ENEM) é o principal mecanismo de acesso ao ensino superior no Brasil, e seus resultados frequentemente refletem disparidades socioeconômicas e educacionais. Este trabalho investiga como fatores familiares (escolaridade dos pais e renda) e escolares (rede de ensino, localização e infraestrutura), em conjunto com o contexto macroeconômico do DF (PIB per capita do IBGE), associam-se ao desempenho em Matemática dos estudantes do Distrito Federal no ENEM entre 2021 e 2023, avaliando em que medida essas relações variam entre grupos. Utilizam-se os microdados do ENEM, o Censo Escolar da Educação Básica e indicadores econômicos oficiais. A metodologia combina exploração visual (matriz de correlação de Pearson e gráficos de barras com mediana), regressão linear múltipla (OLS) e aprendizado de máquina supervisionado com Random Forest Regressor, tendo a nota de Matemática como variável dependente. A amostra reúne 126.874 estudantes assíduos. Os resultados evidenciam que a renda familiar e o capital cultural dos pais explicam mais de 80% da importância preditiva do desempenho, e que a rede privada e a posse de computador conferem vantagens líquidas substantivas mesmo após controle multivariado, oferecendo subsídios para políticas de equidade educacional.

Palavras-chave: ENEM; Matemática; desigualdade educacional; nível socioeconômico; mineração de dados educacionais; Random Forest.

1. Introdução

O ENEM, criado em 1998, tornou-se o principal mecanismo de acesso ao ensino superior brasileiro, sendo usado por universidades públicas via SISU e por programas governamentais como o ProUni e o Fies. Por reunir milhões de participantes todos os anos, constitui uma das fontes mais ricas para investigar o desempenho de concluintes da educação básica e as desigualdades estruturais que os cercam.

A literatura demonstra que o rendimento acadêmico no exame não decorre unicamente do esforço individual. Estudos com microdados do Inep apontam que o desempenho dos candidatos correlaciona-se estreitamente com a origem familiar, a tipologia da escola frequentada e a disponibilidade de recursos pedagógicos e tecnológicos no domicílio. Nesse debate sociológico e educacional, a escolaridade dos pais é recorrentemente identificada como um dos mais potentes preditores do sucesso acadêmico.

No contexto brasileiro, a clivagem entre redes pública e privada configura um dos eixos mais críticos de disparidade. Na avaliação internacional PISA 2018, escolas privadas registraram resultados amplamente superiores aos da rede pública em Matemática, Ciências e Leitura (OECD, 2018), padrão igualmente documentado por Moraes e Belluzzo (2014). Esse diagnóstico fundamentou ações afirmativas indispensáveis, como a Lei de Cotas (Lei nº 12.711/2012), que democratizou o ingresso de egressos da escola pública nas universidades federais. Contudo, pesquisas sobre trajetórias universitárias indicam que déficits de preparo formativo prévio continuam a condicionar o rendimento dos estudantes após o ingresso, reforçando a urgência de diagnosticar essas assimetrias ainda na educação básica.

O Distrito Federal configura um laboratório socioespacial de especial relevância. Reúne um dos maiores PIBs per capita do país e, simultaneamente, aguda segregação socioeconômica entre suas regiões administrativas, com redes pública e privada coabitando o mesmo território federativo. Essa configuração viabiliza examinar desigualdades educacionais em um contexto territorial concentrado, imune à heterogeneidade macrorregional observada em amostras de abrangência nacional.

Optou-se por analisar exclusivamente o desempenho em Matemática em virtude de sua estreita vinculação formativa com as áreas STEM e com a educação em computação. Sendo o ENEM a porta mestra para graduações tecnológicas, quantificar os fatores associados à nota de Matemática permite mapear os gargalos prévios que chegam ao ensino superior. Ademais, concentrar a análise em uma única área de conhecimento evita confundimentos entre domínios distintos e confere precisão às comparações intergrupais.

Assim, a questão norteadora desta pesquisa é: *Como fatores socioeconômicos e educacionais, incluindo a escolaridade dos pais e as características da escola (rede, localização e infraestrutura), se associam ao desempenho em Matemática dos estudantes do Distrito Federal no ENEM, e em que medida essas relações variam entre diferentes grupos e contextos no triênio 2021–2023?* Para respondê-la, articula-se uma abordagem em três frentes: exploração visual descritiva por medianas, regressão linear múltipla e Random Forest Regressor.

2. Background

2.1 Origem social, escola e desigualdade de desempenho

A concepção de que o rendimento escolar traduz a origem social possui sólida tradição na sociologia da educação. Bourdieu e Passeron (1970) conceituam a escola como instituição reprodutora de desigualdades, na medida em que chancela o capital cultural transmitido pelo meio familiar. Nessa formulação, o nível instrucional dos pais opera como proxy do capital cultural incorporado e da ambiência pedagógica doméstica. Pesquisas empíricas com o ENEM no Ceará e no Nordeste confirmam que escolaridade dos genitores e renda domiciliar exercem impacto sistemático e positivo sobre as notas.

2.2 Rede, localização e infraestrutura escolar

Para além da família, o ambiente escolar modula as trajetórias formativas. A discrepância entre as redes pública e privada emerge reiteradamente em avaliações em larga escala, embora parte dessa distância resulte da seleção prévia de perfil socioeconômico atendido por cada subsistema. Torna-se imprescindível contrastar os indicadores de nível socioeconômico (INSE) com atributos estruturais concretos da escola, tais como localização (urbana ou rural), conectividade e laboratórios de informática e ciências.

2.3 Contexto territorial e econômico

O território escolar condiciona o leque de oportunidades: renda regional, acessibilidade a serviços públicos e conectividade variam de forma marcante no Distrito Federal. Estudos sobre o ENEM em outros recortes federativos comprovam clivagens espaciais notáveis. Incorporar a dimensão macroeconômica anual do DF viabiliza testar em que medida o contexto econômico se associa ao desempenho para além do perfil individual do candidato.

2.4 Mineração de dados educacionais e modelos preditivos

A Mineração de Dados Educacionais (EDM) mobiliza métodos computacionais e estatísticos sobre bases de larga escala para produzir conhecimento acionável a políticas públicas. Enquanto a regressão linear múltipla oferece alta interpretabilidade ao estimar coeficientes marginais constantes, algoritmos baseados em árvores como o Random Forest captam não linearidades e interações complexas, ranqueando a relevância relativa de cada atributo (feature importance). Neste estudo, ambas as técnicas se complementam.

2.5 Trabalhos Relacionados

No âmbito da educação em computação no Distrito Federal, destaca-se a pesquisa seminal de Silveira, Holanda e Ramos (2022), intitulada *'Analysis of Student Performance and Social-economic Data in Introductory Computer Science Courses at the University of Brasília'*, apresentada na IEEE Frontiers in Education Conference (FIE). Os autores aplicaram técnicas de Mineração de Dados Educacionais (EDM) e Modelos Lineares Generalizados (GLM) aos dados de calouros matriculados na disciplina de introdução à programação (CS1) nos quatro cursos do Departamento de Ciência da Computação da UnB (Ciência da Computação, Licenciatura em Computação, Engenharia de Computação e Engenharia Mecatrônica) entre 2012 e 2019.

Aquele estudo revelou achados cruciais para o entendimento da evasão e da retenção acadêmica na UnB: o egresso de escola privada apresentou coeficiente positivo e significante no desempenho em programação (+0,796), ao passo que a vulnerabilidade socioeconômica (medida pela concessão de auxílio financeiro e alimentação subsidiada no campus) associou-se negativamente à taxa de aprovação (-0,768). Silveira et al. (2022) constataram ainda que, embora a Lei de Cotas tenha ampliado expressivamente a diversidade socioeconômica na universidade, os cotistas enfrentam maiores taxas de reprovação inicial nas matérias de exatas em decorrência de lacunas de preparo prévio acumuladas ao longo da educação básica.

O presente trabalho dialoga diretamente com os achados de Silveira et al. (2022), porém recuando uma etapa estratégica na cadeia formativa: em vez de diagnosticar a retenção do estudante após seu ingresso na UnB, investigamos a **formação e os filtros na conclusão do ensino médio no próprio DF**. Ao decompor a nota de Matemática no ENEM por meio de regressão econométrica e aprendizado de máquina supervisionado, identificamos a magnitude exata com que o capital cultural familiar, o tipo de escola e a infraestrutura tecnológica doméstica estabelecem os diferenciais de proficiência que, posteriormente, chegam às salas de aula do ensino superior em computação da capital federal.

3.0 Metodologia

3.1 Amostra e Coleta em Streaming

A base de dados integra três fontes abertas oficiais referentes ao triênio 2021–2023: os microdados do ENEM (Inep), os microdados do Censo Escolar da Educação Básica (Inep) e o Produto Interno Bruto dos Municípios (IBGE). Para viabilizar a manipulação dos arquivos volumosos, implementou-se um pipeline em Python que realiza a leitura e filtragem em fluxo contínuo (streaming por blocos de 100.000 linhas) diretamente a partir dos arquivos compactados (.zip), sem descompressão integral em disco.

Foram aplicados três critérios estritos de seleção amostral: (1) participação no Distrito Federal (SG_UF_PROVA == 'DF'); (2) presença efetiva no segundo dia do certame (TP_PRESENCA_MT == 1) e obtenção de nota válida em Matemática; e (3) preenchimento das variáveis familiares essenciais no questionário socioeconômico. A amostra final resultou em N = 126.874 estudantes do Distrito Federal.

3.2 Variáveis e Engenharia de Atributos

A variável dependente (Y) do estudo é a Nota de Matemática e suas Tecnologias (NU_NOTA_MT). Os preditores (X) foram submetidos à engenharia de atributos: (a) a escolaridade do pai (Q001) e da mãe (Q002) foi convertida em anos de escolarização formais (0 a 18 anos), extraindo-se a Maior Escolaridade dos Pais (MAX_ESC_PAIS) como índice de capital cultural máximo do domicílio; (b) a renda familiar (Q006) foi convertida para valores monetários e transformada em escala logarítmica (LOG_RENDA) para corrigir assimetria distributiva; (c) foram criadas variáveis binárias para posse de computador (Q024) e internet (Q025); (d) a dependência administrativa foi codificada em dummies (Privada, Federal, Pública Distrital); e (e) incluíram-se controles de cor/raça (PPI = 1), sexo feminino (1 = F) e dummies dos anos de 2022 e 2023.

3.3 Modelagem Estatística e Preditiva

A estratégia analítica combina duas perspectivas complementares: (1) Regressão Linear Múltipla estimada por Mínimos Quadrados Ordinários (OLS), para inferência paramétrica e medição de efeitos marginais ceteris paribus; e (2) Random Forest Regressor supervisionado com 100 árvores de decisão e profundidade controlada (max_depth = 15). O conjunto amostral foi particionado em 70% para treinamento (N = 88.811) e 30% para teste (N = 38.063), com random_state = 42. A importância relativa de cada atributo foi computada via Mean Decrease in Impurity (MDI).

4.0 Resultados e Discussão

4.1 Análise Exploratória e Visual

A Figura 1 apresenta a matriz de correlação de Pearson entre os fatores investigados e o rendimento em Matemática. A nota exibe forte correlação positiva com a Renda Familiar Mensal (r = 0,47), a Escolaridade do Pai (r = 0,38), a Escolaridade da Mãe (r = 0,36) e a Posse de Computador (r = 0,33), contrastando com correlação negativa com a condição PPI (r = -0,26).

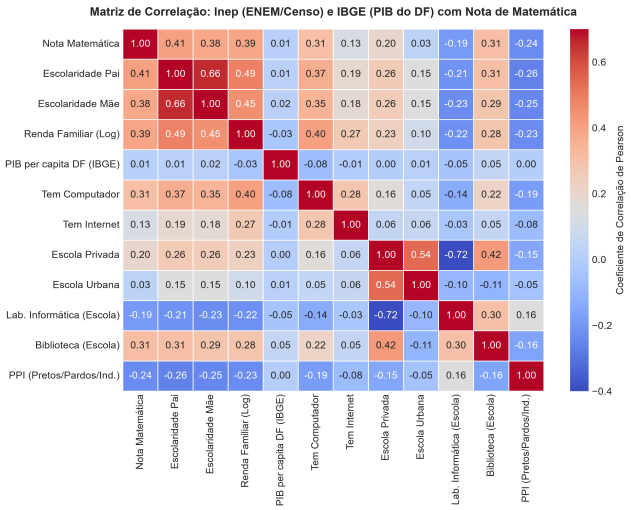


Figura 1. Matriz de Correlação de Pearson: Variáveis Inep, IBGE e Nota de Matemática.

Conforme previsto na formulação do projeto, a Figura 2 apresenta a mediana das notas em Matemática isolando as redes de ensino em cada nível de estudo dos genitores. Observa-se que, enquanto alunos da rede pública de pais sem instrução obtêm mediana de 435,5 pontos, alunos de pais com pós-graduação atingem 565 pontos. Contudo, em qualquer

patamar de escolaridade familiar, a escola privada confere um salto marcante, atingindo mediana superior a 630 pontos nos estratos mais altos (mediana geral de 629,9 pontos versus 501,3 da rede distrital).

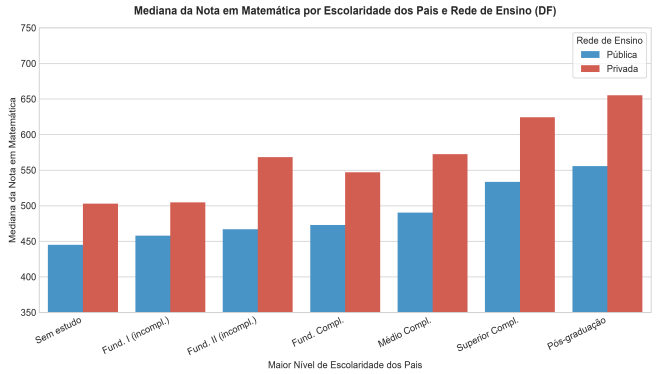


Figura 2. Mediana em Matemática por Maior Escolaridade dos Pais e Rede de Ensino no DF.

A Figura 3 detalha a mediana das notas conforme a disponibilidade de computador no domicílio. Os participantes com computador alcançam mediana agregada de 575,5 pontos, contra 474,3 pontos dos que não dispõem do equipamento (diferencial expressivo de 101,2 pontos). Esse padrão ratifica que os bens tecnológicos domésticos ampliam a capacidade de fixação de conteúdos quantitativos e autoinstrução.

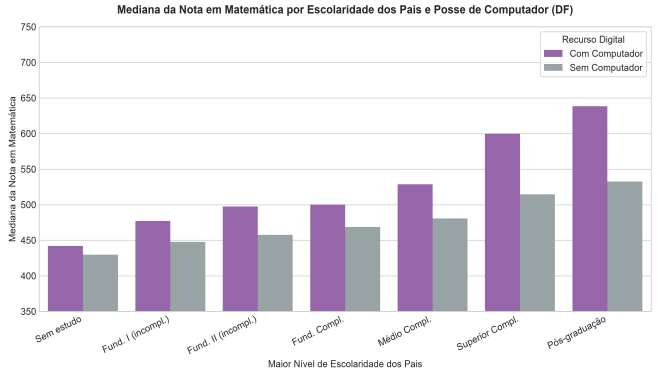


Figura 3. Mediana em Matemática por Escolaridade dos Pais e Posse de Computador no DF.

4.2 Efeitos Marginais: Regressão Linear Múltipla

A Tabela 1 reúne os coeficientes da regressão linear múltipla (OLS). O modelo alcançou $R^2 = 0,2784$ com elevada significância ($F = 4.079$, $p < 0,001$), demonstrando que mais de um quarto da variabilidade das notas em Matemática decorre exclusivamente das variáveis estruturais e familiares inseridas.

Variável	Coef. (β)	Erro P.	t	p-valor
Intercepto (β0)	373,13	2,17	171,6	< 0,001
Esc. Pai (anos)	+4,08	0,09	46,2	< 0,001
Esc. Mãe (anos)	+3,65	0,09	38,9	< 0,001
Log(Renda)	+13,51	0,22	61,7	< 0,001
Tem Computador	+27,46	0,84	32,7	< 0,001
Escola Privada	+44,20	1,15	38,3	< 0,001
Escola Federal	+45,39	2,53	17,9	< 0,001
Cor/Raça PPI	-24,19	0,65	-37,1	< 0,001
Sexo Feminino	-32,85	0,64	-51,5	< 0,001

Tabela 1. Coeficientes da Regressão Linear Múltipla OLS ($R^2 = 0,2784$, N = 126.874).

Os coeficientes revelam que cada ano de estudo adicional do pai e da mãe agrega, respectivamente, +4,08 e +3,65 pontos líquidos à nota. Destaca-se o prêmio institucional da escola privada (+44,20 pontos) e federal (+45,39 pontos) frente à pública distrital, comprovando que o diferencial de desempenho persiste mesmo isolando a renda domiciliar.

4.3 Preditores Não Lineares e Ranking: Random Forest

No conjunto de teste (30%), o Random Forest obteve $R^2 = 0{,}2896$, com erro absoluto médio (MAE) de 85,60 pontos. A Figura 4 expõe o ranking de importância de variáveis (MDI): a Renda Familiar Mensal lidera com 64,05% da força preditiva, seguida pela escolaridade paterna (8,22%) e materna (7,79%), somando 16,01% para o capital cultural. Dispositivos digitais, sexo e tipologia escolar complementam a capacidade preditiva.

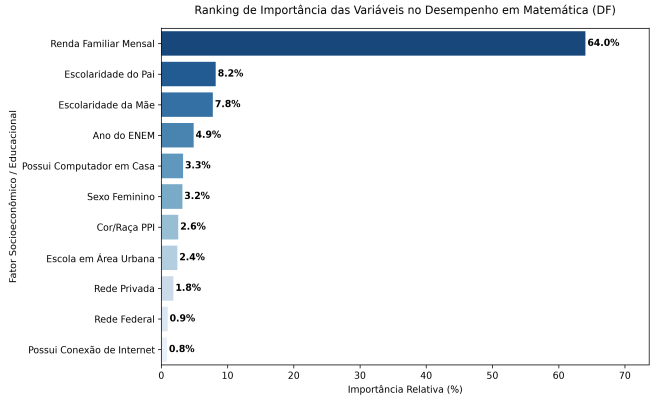


Figura 4. Ranking de Importância de Variáveis via Random Forest Regressor (MDI).

Dimensão / Subcategoria	N	Média	Mediana
Rede Privada	18.377	621,1	629,9
Rede Federal (IFB)	2.207	601,0	600,5
Rede Pública Distrital	26.063	511,6	501,3
Pais: Pós-graduação	39.018	623,7	633,9
Pais: Ensino Superior	27.731	586,2	588,1
Pais: Ensino Médio	42.617	521,1	509,5
Pais: Sem estudo	1.574	448,8	435,5
Possui Computador	105.100	578,0	575,5
Não Possui Computador	35.349	487,5	474,3

Tabela 2. Estatísticas Descritivas de Matemática por Subgrupo no DF (N = 126.874).

5.0 Conclusão

Este trabalho investigou as determinantes socioeconômicas e escolares do desempenho em Matemática no ENEM no Distrito Federal entre 2021 e 2023. A articulação entre regressão linear múltipla e Random Forest demonstrou que as condições familiares exercem influência decisiva: renda domiciliar e capital cultural dos genitores respondem por mais de 80% do poder preditivo das notas.

Ao estabelecer diálogo com a literatura do Departamento de Ciência da Computação da UnB, em especial o trabalho de Silveira et al. (2022), esta pesquisa evidencia que as barreiras de rendimento e evasão observadas nas disciplinas introdutórias de computação (CS1) encontram raízes estruturais profundas já na educação básica. Políticas públicas de equalização de oportunidades devem priorizar a redução do abismo de infraestrutura entre escolas públicas e privadas, a garantia de acesso universal a dispositivos digitais e o fortalecimento de programas de nivelamento em ciências exatas.

Referências

BOURDIEU, P.; PASSERON, J.-C. **La reproduction: éléments pour une théorie du système d'enseignement**. Paris: Éditions de Minuit, 1970.

IBGE. **Produto Interno Bruto dos Municípios 2021–2023**. Rio de Janeiro: Instituto Brasileiro de Geografia e Estatística, 2024.

INEP. **Microdados do Censo Escolar da Educação Básica (2021–2023)**. Brasília: Inep, 2024.

INEP. **Microdados do Exame Nacional do Ensino Médio (2021–2023)**. Brasília: Inep, 2024.

MORAES, B.; BELLUZZO, W. O diferencial de desempenho entre escolas públicas e privadas no Brasil. **Revista Brasileira de Economia**, v. 68, n. 4, p. 451–475, 2014.

OECD. **PISA 2018 Results (Volume I): What Students Know and Can Do**. Paris: PISA, OECD Publishing, 2019.

SILVEIRA, R. F.; HOLANDA, M.; RAMOS, G. N. Analysis of Student Performance and Social-economic Data in Introductory Computer Science Courses at the University of Brasília. In: **2022 IEEE Frontiers in Education Conference (FIE)**. Uppsala: IEEE, 2022. p. 1–8.